

***Методы машинного обучения:
метрические методы***

Что представляет собой метод ближайших соседей?


Гипотеза компактности: близкие объекты лежат в одном классе.

Метод ближайших соседей (англ. k-nearest neighbors algorithm или метод kNN):

будем делать вывод о классе объекта x на основе классов
нескольких ближайших объектов из обучающей выборки.

Метод kNN был описан американскими статистиками Э. Фиксом и Д. Ходжесом в 1951 году и позже расширен в Т. Ковером в 1967.

Out[-j]=



• Класс 1
• Класс 2


В чём заключаются особенности метода k -ближайших соседей? Что понимается под “проклятием размерности”?

Пусть все данные в единичном кубе в $\mathbb{R}^d$.
Точки датасета равномерно распределены в кубе в $\mathbb{R}^d$.
Если a сторона параллелепипеда с $k \approx 10$ ближайшими соседями, то при $M \approx 1000$


	Размерность d	Значение a
	2	0.1
	10	0.630957
	100	0.954993
	1000	0.995405

Out[]:TableForm

На что влияет выбор значения k для метода ближайших соседей?





Примеры для $k = 1$, $k = 7$, $k = 15$.




Что такое взвешенный kNN?

***Методы машинного обучения:
логические методы***


Опишите общую суть работы метода решающих деревьев



Что представляет собой метод решающих деревьев для решения задачи классификации?




В датасете 9 синих и 11 жёлтых шариков.




$$S(\mathcal{D}) = \sum_{k=1}^2 p_k \log_2 \frac{1}{p_k} = \frac{9}{20} \log_2 \frac{1}{\frac{9}{20}} + \frac{11}{20} \log_2 \frac{1}{\frac{11}{20}} \approx 1.$$

$$S(\mathcal{D}_{\text{left}}) = \frac{5}{13} \log_2 \frac{1}{\frac{5}{13}} + \frac{8}{13} \log_2 \frac{1}{\frac{8}{13}} \approx 0.96, \quad S(\mathcal{D}_{\text{right}}) = \frac{1}{7} \log_2 \frac{1}{\frac{1}{7}} + \frac{6}{7} \log_2 \frac{1}{\frac{6}{7}} \approx 0.6.$$

$$\text{Gain}(\mathcal{D}, [x \leq 12]) = S(\mathcal{D}) - \left(\frac{13}{20} S(\mathcal{D}_{\text{left}}) + \frac{7}{20} S(\mathcal{D}_{\text{right}}) \right) \approx 0.16.$$





Сформулируйте общий алгоритм построения дерева решений и способ получения предсказаний. Приведите виды критериев остановки.

Перечислите преимущества и недостатки метода решающих деревьев.