


***Методы машинного обучения:
метод опорных векторов***

Метод опорных векторов (англ. Support Vector Machines, SVM) создан в 1970-х годах 20 века сотрудниками Института проблем управления АН СССР В. Н. Вапником (р. 1936) и А. Я. Червоненкисом (1938-2014) (изначально известен как метод обобщённого портрета).

Суть SVM для задачи классификации: провести наилучшим образом разделяющую поверхность (англ. decision boundary) между объектами разных классов.

Приведите математическую постановку задачи линейного SVM для задачи бинарной классификации.

Надо найти такое положение разделяющей гиперплоскости,
при котором расстояние между гиперплоскостью и ближайшими к ней точками разных классов,
находящихся по разные стороны от этой гиперплоскости, **максимально**.



Расстояние (или отступ) между точкой x от гиперплоскостью, заданной $\langle w, x \rangle + b = 0$, равно

$$\frac{|\langle w, x \rangle + b|}{\|w\|}.$$

Расстояние от разделяющей гиперплоскости до ближайшего объекта из обучающей выборки X

$$\gamma(w, b) = \min_{x \in X} \frac{|\langle w, x \rangle + b|}{\|w\|} \rightarrow \max_{w, b}$$

Будем считать, что $\mathcal{Y} = \{-1, 1\}$.

Промежуточная формулировка:

$$\max_{w,b} \gamma(w, b) = \max_{w,b} \left(\min_{x \in X} \frac{|\langle w, x \rangle + b|}{\|w\|} \right)$$

при условиях, что

$$y_i(\langle w, x_i \rangle + b) \geq 0 \quad \forall i = 1, \dots, M.$$

Промежуточная формулировка 2:

$$\operatorname{argmin}_{w,b} \|w\|^2$$

при условиях, что

$$\min_{x \in X} |\langle w, x \rangle + b| = 1 \text{ и}$$

$$y_i(\langle w, x_i \rangle + b) \geq 0 \quad \forall i = 1, \dots, M.$$

Итоговая формулировка:

$$\operatorname{argmin}_{w,b} \langle w, w \rangle$$

при условиях, что

$$y_i(\langle w, x_i \rangle + b_i) \geq 1 \quad \forall i = 1, \dots, M$$

Для w^{opt} параметр b^{opt} подбирается так, что $\min_{x \in X} |\langle w, x \rangle + b| = 1$.

Как минимум двух обучающих примеров будет выполнено

$$y_i(\langle w^{\text{opt}}, x_i \rangle + b^{\text{opt}}) = 1.$$

Такие точки x_i называют **опорными векторами** (англ. support vectors).

Они ближе всего к разделяющей гиперплоскости.

Приведите двойственную математическую постановку задачи линейного SVM для задачи бинарной классификации.

Общая задача условной минимизации:

$$\min_{w \in \mathbb{R}^N} f(w)$$

при условиях, что

$$g_i(w) \leq 0, \quad i = 1, \dots, M.$$

Обозначим за $D_{g_1, \dots, g_M}$ множество в $\mathbb{R}^N$ вида

$$D_{g_1, \dots, g_M} = \{w \in \mathbb{R}^N : g_i(w) \leq 0 \quad \forall i = 1, \dots, M\}.$$

Цель задачи условной минимизации в том, чтобы найти:

$$w^* = \operatorname{argmin}_{w \in D_{g_1, \dots, g_M}} f(w).$$

Теорема Каруша-Куна-Такера. Пусть $f, g_1, \dots, g_M: \mathbb{R}^N \rightarrow \mathbb{R}$ выпуклы вниз и непрерывно-дифференцируемы, при этом существует $w \in \mathbb{R}^N$, что

$$g_i(w) < 0 \quad \forall i = 1, \dots, M.$$

Обозначим за L функцию Лагранжа

$$L(w, \lambda_1, \dots, \lambda_M) = f(w) + \sum_{i=1}^M \lambda_i g_i(w),$$

Тогда для любой точки $w^* \in D_{g_1, \dots, g_M}$ следующий условия **эквивалентны**.

1. $f(w^*) = \min_{w \in D_{g_1, \dots, g_M}} f(w);$
 2. найдутся $\lambda_1^*, \dots, \lambda_M^* \in \mathbb{R} : \begin{cases} \lambda_i^* \geq 0 & \forall i = 1, \dots, M, \\ \lambda_i^* g_i(w^*) = 0 & \forall i = 1, \dots, M, \end{cases}$ при которых
- $$\text{grad}_w L(w^*, \lambda_1^*, \dots, \lambda_M^*) = 0.$$

Функция Лагранжа для задачи **линейного SVM**

$$L(w, b, \lambda) = \frac{\langle w, w \rangle}{2} - \sum_{i=1}^M \lambda_i (y_i (\langle w, x_i \rangle + b) - 1)$$

Стационарная точка:

$$\text{grad}_w L(w, b, \lambda) = w - \sum_{i=1}^M \lambda_i y_i x_i = 0,$$

$$\frac{\partial L}{\partial b}(w, b, \lambda) = - \sum_{i=1}^M \lambda_i y_i = 0.$$

По теореме ККТ надо найти вектор w^* , число b^* и набор чисел $\lambda_1^*, \dots, \lambda_M^* \geq 0$ такие, что

$$w^* = \sum_{i=1}^M \lambda_i^* y_i x_i, \quad \sum_{i=1}^M \lambda_i^* y_i = 0$$

и

$$g_i(w^*, b^*) = y_i(\langle w^*, x_i \rangle + b^*) - 1 \geq 0,$$

$$\lambda_i^* g_i(w^*, b^*) = \lambda_i^* (y_i(\langle w^*, x_i \rangle + b^*) - 1) = 0,$$

$$\forall i = 1, \dots, M.$$

Эта задача равносильна: найти вектор w^* , число b^* и набор чисел $\lambda_1^*, \dots, \lambda_M^* \geq 0$ такие, что

$$w^*, b^*, \lambda^* = \operatorname{argmin}_{w, b, \lambda} \sum_{i=1}^M \lambda_i (y_i(\langle w, x_i \rangle + b) - 1)$$

при условиях, что

$$w = \sum_{i=1}^M \lambda_i y_i x_i, \quad \sum_{i=1}^M \lambda_i y_i = 0,$$

$$y_i(\langle w, x_i \rangle + b) - 1 \geq 0, \quad \forall i = 1, \dots, M.$$

Итоговый вид двойственной задачи минимизации

$$\min_{\lambda} \left(\sum_{i=1}^M \sum_{j=1}^M y_i y_j \lambda_j \langle x_i x_j \rangle - \sum_{i=1}^M \lambda_i \right)$$

при условиях, что

$$\sum_{i=1}^M \lambda_i y_i = 0 \text{ и } \lambda_i \geq 0, \quad i = 1, \dots, M.$$

Или

$$\min_{\lambda} \left(\lambda^T Q \lambda - \sum_{i=1}^M \lambda_i \right), \quad \text{где} \quad Q = \begin{pmatrix} y_1 y_1 \langle x_1, x_1 \rangle & y_1 y_2 \langle x_1, x_2 \rangle & \dots & y_1 y_M \langle x_1, x_M \rangle \\ y_2 y_1 \langle x_2, x_1 \rangle & y_2 y_2 \langle x_2, x_2 \rangle & \dots & y_2 y_M \langle x_2, x_M \rangle \\ \dots & \dots & \dots & \dots \\ y_M y_1 \langle x_M, x_1 \rangle & y_M y_2 \langle x_M, x_2 \rangle & \dots & y_M y_M \langle x_M, x_M \rangle \end{pmatrix}$$

при условиях, что

$$\langle y, \lambda \rangle = 0 \text{ и } \lambda \geq 0.$$

По найденному решению λ^* находим

$$w^* = \sum_{i=1}^M \lambda_i^* y_i x_i.$$

Если $\lambda_i^* > 0$, то x_i — это **опорный вектор**.

b^* находим из условия :

$$y(\langle w^*, x \rangle + b^*) = 1, \text{ где } x \in SV.$$

Если при этом

$$y_i(\langle w^*, x_i \rangle + b^*) - 1 \geq 0, \quad \forall i = 1, \dots, M,$$

то получим решение и исходной задачи (если данные не были линейно разделимы, то это условие не будет выполнено).

Итоговая модель для предсказания классов новых точек имеет вид

$$g_{w,b}(x) = \text{sign}(\langle w^*, x \rangle + b^*) = \text{sign}\left(\sum_{i=1}^M \lambda_i^* y_i \langle x_i, x \rangle + b^*\right).$$

Приведите математическую постановку задачи Soft Linear SVM для задачи бинарной классификации.

Linear SVM работает, когда данные **линейно разделимы**.

Введём новые переменные ξ_i , $i = 1, \dots, M$ (англ. slack variables), что ослабить условия в задаче Linear SVM.

$$y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, M.$$

И будем решать задачу минимизацию в виде

$$\min_{w, b, \xi} \langle w, w \rangle + C \sum_{i=1}^M \xi_i$$

при условиях, что

$$y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i,$$

$$\xi_i \geq 0, \quad i = 1, \dots, M.$$

C — это гиперпараметр.

Функция Лагранжа для данной задачи имеет вид:

$$L(w, b, \xi, \lambda, \beta) = \langle w, w \rangle + C \sum_{i=1}^M \xi_i - \sum_{i=1}^M \lambda_i (y_i (\langle w, x_i \rangle + b) - 1 + \xi_i) - \sum_{i=1}^M \beta_i \xi_i.$$

Используя теорему ККТ и повторяя шаги для получения двойственной задачи, получим:

$$\min_{\lambda, \xi, b} \left(\lambda^T Q \lambda - \sum_{i=1}^M \lambda_i + C \sum_{i=1}^M \xi_i \right),$$

при условиях, что


$$\langle y, \lambda \rangle = 0, \quad C \geq \lambda \geq 0, \quad \xi \geq 0,$$

$$y_i (\langle w, x_i \rangle + b) \geq 1 - \xi_i, \quad i = 1, \dots, M, \quad \text{при } w = \sum_{i=1}^M \lambda_i y_i x_i.$$

По найденному решению λ^* находим $w^* = \sum_{i=1}^M \lambda_i^* y_i x_i$.

Если $y_i (\langle w^*, x_i \rangle + b^*) \geq 1$, то x_i — это опорный вектор.

**В чём идея Kernel SVM
для задачи бинарной классификации.**



Исходные данные не разделимы линейно, но их можно вложить в пространство большей размерности, где они станут линейно разделимы. Требуется найти новый набор признаков $z = \Phi(x)$, в котором задача линейно разделима и применить Linear SVM.

Linear SVM:

$$\min_{\lambda} \left(\lambda^T Q \lambda - \sum_{i=1}^M \lambda_i \right), \quad \text{где} \quad Q = \begin{pmatrix} y_1 y_1 \langle x_1, x_1 \rangle & y_1 y_2 \langle x_1, x_2 \rangle & \dots & y_1 y_M \langle x_1, x_M \rangle \\ y_2 y_1 \langle x_2, x_1 \rangle & y_2 y_2 \langle x_2, x_2 \rangle & \dots & y_2 y_M \langle x_2, x_M \rangle \\ \dots & \dots & \dots & \dots \\ y_M y_1 \langle x_M, x_1 \rangle & y_M y_2 \langle x_M, x_2 \rangle & \dots & y_M y_M \langle x_M, x_M \rangle \end{pmatrix}$$

при условиях, что

$$\langle y, \lambda \rangle = 0 \text{ и } \lambda \geq 0.$$

Итоговая модель для предсказания классов новых точек имеет вид

$$g_{w,b}(x) = \text{sign}(\langle w^*, x \rangle + b^*) = \text{sign} \left(\sum_{i=1}^M \lambda_i^* y_i \langle x_i, x \rangle + b^* \right).$$

Тогда для решения задачи надо уметь считать скалярные произведения:

$$\langle z_i, z_j \rangle, \langle z_i, z \rangle, \text{ где } z_i = \Phi(x_i), z = \Phi(x).$$

Если найдётся такая **функция-ядро** $K: \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$, что

$$\langle z, z' \rangle = K(x, x'),$$

то формально и явно знать Φ не требуется. При этом

$$\min_{\lambda} \left(\lambda^T Q \lambda - \sum_{i=1}^M \lambda_i \right), \quad \text{где} \quad Q = \{y_i y_j K(x_i, x_j)\}_{i,j}$$

Итоговая модель для предсказания классов новых точек имеет вид

$$g_{w,b}(x) = \text{sign}(\langle w^*, x \rangle + b^*) = \text{sign} \left(\sum_{i=1}^M \lambda_i^* y_i K(x_i, x) + b^* \right).$$

Пример. Пусть $x = (x_1, x_2)$, $y = (y_1, y_2)$.

$$z = \Phi(x) = (1, \sqrt{2} x_1, \sqrt{2} x_2, x_1^2, x_2^2, \sqrt{2} x_1 x_2),$$

$$z' = \Phi(y) = (1, \sqrt{2} y_1, \sqrt{2} y_2, y_1^2, y_2^2, \sqrt{2} y_1 y_2),$$

$$\langle z, z' \rangle = 1 + 2 x_1 y_1 + 2 x_2 y_2 + x_1^2 y_1^2 + x_2^2 y_2^2 + 2 x_1 y_2 x_1 y_2.$$

В данном случае, можно взять функцию ядро в виде

$$K(x, y) = (1 + \langle x, y \rangle)^2 = (1 + x_1 y_1 + x_2 y_2)^2 = 1 + 2 x_1 y_1 + 2 x_2 y_2 + x_1^2 y_1^2 + x_2^2 y_2^2 + 2 x_1 y_2 x_1 y_2.$$

Примеры ядер.


1. Полиномиальное ядро: $K(x, x') = (a \langle x, x' \rangle + b)^n$.

2. $K(x, x') = \tanh(c \langle x, x' \rangle + h)$

3. Ядро Лапласа: $K(x, x') = \exp(-\gamma |x - x'|)$


4. RBF ядро: $K(x, x') = \exp(-\gamma \|x - x'\|^2)$.

**Что такое ансамблирование алгоритмов и
какие бывают типы ансамблирования?
Опишите ансамблирование по принципу большинства голосов.**




Опишите общую суть ансамблирования алгоритмов методом бэггинга.





Опишите общую суть и алгоритм работы метода случайного леса.

Опишите общую суть ансамблирования алгоритмов методом адаптивного бустинга.



Алгоритм адаптивного бустинга для решения задачи бинарной классификации.
Пусть $\mathcal{Y} = \{-1, 1\}$ и имеется m моделей, которые также возвращают ответы -1 и 1 .

Шаг 0. Всем объектам в датасете присваивается одинаковый вес $w_1 = w_M = \frac{1}{M}$.

Шаг 1. В цикле для $j = 1, \dots, m$:

1. модель $h_j(x)$ обучается на датасете $\mathcal{D}_{\text{train}}$, при обучении минимизируется функционал

$$e_j = Q(h_j, \mathcal{D}_{\text{train}}, w) = \sum_{i=1}^M w_i [y_i \neq h_j(x_i)], \quad \text{— это взвешенная оценка ошибки классификации.}$$


2. веса объектов корректируются, чтобы "подсветить" неверно классифицируемые объекты.

$$\text{Находим } \alpha_j = \frac{1}{2} \ln \frac{1 - e_j}{e_j}; \quad \text{далее } w_i := w_i e^{-\alpha_j y_i h_j(x_i)},$$

$$\text{и } w_i = \frac{w_i}{\sum w_i}, \quad i = 1, \dots, M.$$

Шаг 2. Итоговая модель формируется по правилу

$$g(x) = \text{sign} \left(\sum_{j=1}^m \alpha_j h_j(x) \right).$$



Опишите общую суть ансамблирования алгоритмов методом градиентного бустинга.

Шаг 0. Обучить модель $h_1(x)$. Установить $g_1(x) = h_1(x)$.

Шаг 1.

В цикле для $k = 2, \dots, K$:

найти новые значения целевой переменной:

$$y_i^{(k)} = - \frac{\partial \mathcal{L}(x_i, z)}{\partial z} \Big|_{z=g_{k-1}(x_i)},$$

сформировать датасет $\mathcal{D}^{(k)} = \{(x_i, y_i^{(k)})\}, \quad i = 1, \dots, M\}$,

обучить модель $h_k(x)$ на датасете $\mathcal{D}^{(k)}$,

сформировать $g_k(x) = g_{k-1}(x) + \alpha h_k(x)$.

Шаг 2. Вернуть итоговую модель $g_K(x)$.